

Predicción de Retornos Bancarios Mediante Mecanismos de Atención Cruzada

Borjas Bernaola, Gerald Marcelo Fernando

Universidad de Ingeniería y Tecnología

Lima, Peru

gerald.borjas@utec.edu.pe

Abstract—El pronóstico financiero es un desafío clásico en Machine Learning debido a la alta volatilidad del mercado. Tradicionalmente, se usan modelos que analizan las acciones de forma aislada. Como aplicación empírica, este proyecto busca predecir los retornos de JPMorgan Chase utilizando redes neuronales basadas en Transformers. En lugar de utilizar arquitecturas complejas de la literatura reciente, se implementará una adaptación simplificada inspirada en el modelo MASTER. El enfoque central es explorar el mecanismo de atención cruzada (Cross-Attention), utilizando el comportamiento histórico de bancos competidores (Bank of America, Citigroup y Wells Fargo) como contexto para guiar las predicciones sobre el banco objetivo. Este diseño permite reducir el costo computacional del entrenamiento y analizar si la red logra capturar cómo las instituciones financieras se influyen mutuamente. Finalmente, el rendimiento de esta implementación se comparará de forma práctica contra modelos de línea base tradicionales vistos en el estado del arte, evaluando métricas como el Error Absoluto Medio (MAE) para determinar si la integración multivariada de bancos competidores justifica el uso de algoritmos de aprendizaje profundo en la gestión de riesgos.

Index Terms—Aprendizaje profundo, Atención cruzada, Pronóstico financiero, Redes neuronales Transformer, Series temporales multivariadas

I. INTRODUCCIÓN

La predicción precisa de activos financieros es altamente compleja debido a la volatilidad del mercado y la influencia de factores macroeconómicos externos. La mayoría de los enfoques de Machine Learning modelan el precio de una acción basándose únicamente en su propio historial (autorregresión), fallando en capturar correlaciones temporales cruzadas («cross-time») generadas por el comportamiento global del mercado. En el sector bancario, comprender cómo las fluctuaciones del mercado impactan a una entidad específica es crítico para la gestión del riesgo.

A. Objetivos del proyecto

- 1) Desarrollar e implementar una arquitectura basada en Transformers con un mecanismo de atención cruzada (Cross-Attention) adaptado para datos financieros de alta frecuencia.
- 2) Reducir la complejidad dimensional modelando el «estado del mercado» a través de un panel selecto de los principales bancos pares (Bank of America, Citigroup, Wells Fargo), en lugar de analizar el universo bursátil completo.

- 3) Evaluar la precisión predictiva del modelo propuesto utilizando métricas de error (MAE, RMSE) en la predicción del comportamiento de JPMorgan Chase (JPM), comparándolo con modelos convencionales.

B. Dataset utilizado

Se utilizará un dataset creado para el proyecto mediante la extracción de datos históricos diarios a través de la API yfinance. El conjunto comprenderá las series temporales del precio de cierre ajustado y volumen de transacciones del banco objetivo (JPM) y un panel de características de bancos guía (BAC, C, WFC) durante la última década. Los datos crudos serán preprocesados en retornos logarítmicos y métricas de volatilidad rodante, garantizando la estacionariedad y la coherencia matemática para el entrenamiento de la red.

II. REVISIÓN BIBLIOGRÁFICA

El modelamiento de series temporales financieras ha evolucionado hacia arquitecturas de aprendizaje profundo capaces de capturar dependencias no lineales. La literatura identifica los mecanismos de atención como herramientas robustas para abordar la volatilidad.

En la base de esta investigación se encuentra el trabajo de [1], quienes introducen el modelo MASTER, argumentando que las correlaciones entre activos ocurren de manera momentánea y cruzada. Su propuesta de guiar la predicción con información global fundamenta el uso de atención cruzada en este proyecto. Asimismo, [2] proponen «Stockformer», reforzando que el pronóstico debe tratarse como un problema multivariado y no como una autorregresión aislada.

Pese a la potencia de los Transformers, [3] señala debilidades en la captura de patrones locales, sugiriendo arquitecturas híbridas. No obstante, [4] demuestran que la arquitectura de atención multi-cabezal supera consistentemente a modelos recurrentes como LSTM en la caracterización de dinámicas de mercado. Finalmente, [5] validan la robustez de estos modelos en entornos de alta volatilidad, permitiendo filtrar el ruido inherente a los datos financieros.

REFERENCES

- [1] T. Li, Z. Liu, Y. Shen, X. Wang, H. Chen, y S. Huang, «MASTER: Market-Guided Stock Transformer for Stock Price Forecasting», en *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024.
- [2] S. Li, Z. B. Schulwolf, y R. Mäkeläinen, «Transformer Based Time-Series Forecasting For Stock», *arXiv preprint arXiv:2502.09625*, 2025.

- [3] S. Wang, «A Stock Price Prediction Method Based on BiLSTM and Improved Transformer», *IEEE Access*, vol. 11, pp. 74800-74810, 2023.
- [4] L. Mozaffari y J. Zhang, «Predictive Modeling of Stock Prices Using Transformer Model», en *Proceedings of the 9th International Conference on Machine Learning Technologies*, 2024.
- [5] T. Muhammad *et al.*, «Transformer-based deep learning model for stock price prediction: A case study on Bangladesh stock market», *arXiv preprint arXiv:2208.08300*, 2022.